



Université de
Technologie de
Compiègne

LO17/AI31 : Indexation et Recherche d'Information

Rapport de Projet — RAG sur le Code de la propriété
intellectuelle

Membres du groupe :

Géo SAGLIO (GI05)	Contribution : ... %
Matéo GROS (GI04)	Contribution : ... %
Mathilde WALLUT (GI04)	Contribution : ... %
Julien HELLEC (GI04)	Contribution : ... %

UV : LO17 / AI31
Enseignante : Soundouss MESSOUDI



Sommaire

Introduction	2
1 Choix du sujet et préparation du corpus	3
1.1 Motivation du sujet	3
1.2 Source des données : Legifrance	3
1.3 Ingestion et nettoyage du corpus	3
1.4 Statistiques du corpus	3
2 Architecture et pipeline RAG	4
2.1 Vue d'ensemble du pipeline	4
2.2 Chunking et indexation	4
2.3 Récupération et reranking	4
2.4 Génération de la réponse	4
2.5 Choix techniques principaux	4
3 Évaluation et gestion des hallucinations	5
3.1 Protocole d'évaluation	5
3.2 Mise en oeuvre	5
3.3 Résultats	5
3.4 Gestion des hallucinations	5
4 Application Streamlit et déploiement	6
4.1 Interface utilisateur	6
4.2 Configuration et reproductibilité	6
4.3 Déploiement (bonus)	6
Conclusion	7



Introduction

Contexte

Problématique

Objectifs

Plan du rapport



Partie 1

Choix du sujet et préparation du corpus

- 1.1 Motivation du sujet**
- 1.2 Source des données : Legifrance**
- 1.3 Ingestion et nettoyage du corpus**
- 1.4 Statistiques du corpus**



Partie 2

Architecture et pipeline RAG

- 2.1 Vue d'ensemble du pipeline**
- 2.2 Chunking et indexation**
- 2.3 Récupération et reranking**
- 2.4 Génération de la réponse**
- 2.5 Choix techniques principaux**



Partie 3

Évaluation et gestion des hallucinations

- 3.1 Protocole d'évaluation**
- 3.2 Mise en oeuvre**
- 3.3 Résultats**
- 3.4 Gestion des hallucinations**



Partie 4

Application Streamlit et déploiement

- 4.1 Interface utilisateur**
- 4.2 Configuration et reproductibilité**
- 4.3 Déploiement (bonus)**



Conclusion

Résumé du travail

Bilan

Contributions

- Géo SAGLIO (GI05) – ... % : ...
- Matéo GROS (GI04) – ... % : ...
- Mathilde WALLUT (GI04) – ... % : ...
- Julien HELLEC (GI04) – ... % : ...