



Université de  
Technologie de  
Compiègne

---

## **LO17/AI31 : Indexation et Recherche d'Information**

Rapport de Projet — RAG sur le Code de la propriété  
intellectuelle

---

### **Membres du groupe :**

|                        |                      |
|------------------------|----------------------|
| Géo SAGLIO (GI05)      | Contribution : ... % |
| Matéo GROS (GI03)      | Contribution : ... % |
| Mathilde WALLUT (GI04) | Contribution : ... % |
| Julien HELLEC (GI04)   | Contribution : ... % |

UV : LO17 / AI31  
Enseignante : Soundouss MESSOUDI



# Sommaire

|                                                   |          |
|---------------------------------------------------|----------|
| <b>Introduction</b>                               | <b>2</b> |
| <b>1 Choix du sujet et préparation du corpus</b>  | <b>3</b> |
| 1.1 Motivation du sujet . . . . .                 | 3        |
| 1.2 Source des données : Legifrance . . . . .     | 3        |
| 1.3 Ingestion et nettoyage du corpus . . . . .    | 3        |
| <b>2 Architecture et pipeline RAG</b>             | <b>4</b> |
| 2.1 Vue d'ensemble du pipeline . . . . .          | 4        |
| 2.2 Chunking et indexation . . . . .              | 4        |
| 2.3 Récupération et reranking . . . . .           | 4        |
| 2.4 Génération de la réponse . . . . .            | 4        |
| 2.5 Choix techniques principaux . . . . .         | 4        |
| <b>3 Évaluation et gestion des hallucinations</b> | <b>5</b> |
| 3.1 Protocole d'évaluation . . . . .              | 5        |
| 3.2 Mise en oeuvre . . . . .                      | 5        |
| 3.3 Résultats . . . . .                           | 5        |
| 3.4 Gestion des hallucinations . . . . .          | 5        |
| <b>4 Application Streamlit et déploiement</b>     | <b>6</b> |
| 4.1 Interface utilisateur . . . . .               | 6        |
| 4.2 Configuration et reproductibilité . . . . .   | 6        |
| 4.3 Déploiement (bonus) . . . . .                 | 6        |
| <b>Conclusion</b>                                 | <b>7</b> |



---

# Introduction

Contexte

Problématique

Objectifs

Plan du rapport



# Partie 1

## Choix du sujet et préparation du corpus

### 1.1 Motivation du sujet

L'origine de ce projet tient à la situation concrète d'un membre du groupe, inscrit à l'UV GE28 portant sur le droit de la propriété intellectuelle. Cette matière exige des références constantes à des textes législatifs, ce qui rend la révision laborieuse sans un outil capable de retrouver rapidement l'article pertinent parmi des centaines.

Le droit constitue un terrain d'application particulièrement adapté aux systèmes RAG. D'une part, l'ensemble du corpus est structuré et officiellement sourcé : toute affirmation doit pouvoir s'appuyer sur un article précis, ce qui exclut par nature toute réponse inventée. D'autre part, le volume des textes législatifs rend leur lecture exhaustive inaccessible à quiconque n'exerce pas le droit à titre professionnel. Un assistant capable d'interroger ce corpus et de citer ses sources répond ainsi directement à ces deux contraintes.

### 1.2 Source des données : Legifrance

Le site choisi pour réaliser le RAG est le site officiel du gouvernement français [https://www.legifrance.gouv.fr/codes/texte\\_lc/LEGITEXT000006069414](https://www.legifrance.gouv.fr/codes/texte_lc/LEGITEXT000006069414). Ce dernier contient 915 articles distincts traitant du Code de la Propriété Intellectuelle, séparé en trois parties distinctes : la propriété littéraire et artistique, la propriété industrielle et les dispositions relatives à l'Outre-mer. Le site est régulièrement mis à jour et les articles abrogés sont supprimés, les informations renvoyées par le RAG sont donc nécessairement d'actualité.

### 1.3 Ingestion et nettoyage du corpus



---

## **Partie 2**

# **Architecture et pipeline RAG**

- 2.1 Vue d'ensemble du pipeline**
- 2.2 Chunking et indexation**
- 2.3 Récupération et reranking**
- 2.4 Génération de la réponse**
- 2.5 Choix techniques principaux**



---

## **Partie 3**

# **Évaluation et gestion des hallucinations**

- 3.1 Protocole d'évaluation**
- 3.2 Mise en oeuvre**
- 3.3 Résultats**
- 3.4 Gestion des hallucinations**



---

## **Partie 4**

# **Application Streamlit et déploiement**

- 4.1 Interface utilisateur**
- 4.2 Configuration et reproductibilité**
- 4.3 Déploiement (bonus)**



---

# Conclusion

Résumé du travail

Bilan

Contributions

- Géo SAGLIO (GI05) – ... % : ...
- Matéo GROS (GI04) – ... % : ...
- Mathilde WALLUT (GI04) – ... % : ...
- Julien HELLEC (GI04) – ... % : ...